

Praca domowa nr 2

Mateusz Markowski gr 1.2/4

Zadanie 1

Przygotowanie danych oraz obliczenie dla nich odpowiednio wielkości próbki, średniej wartości próbki, wariancji oraz odchylenia standardowego.

```
men=c(9.88, 9.97, 10.00, 10.02, 10.04, 10.06, 10.07, 10.08, 10.09, 10.09,
      10.11, 10.11, 10.12, 10.13, 10.13, 10.14, 10.16, 10.16, 10.19, 10.20, 10.21,
      10.22, 10.22, 10.22, 10.22, 10.23, 10.24, 10.26, 10.27, 10.28, 10.29, 10.30,
      10.30, 10.31, 10.31, 10.31, 10.34, 10.35, 10.35, 10.38, 10.40, 10.41, 10.48,
      10.53, 10.54, 10.55, 10.59, 10.65, 10.65, 10.69, 10.71, 10.84, 10.90, 10.94)
kob= c(10.83, 10.93, 10.94, 10.96, 10.97, 10.97, 10.99, 11.00, 11.01,
      11.04, 11.06, 11.07, 11.07, 11.07, 11.08, 11.12, 11.13, 11.14, 11.14, 11.18,
      11.19, 11.22, 11.22, 11.27, 11.28, 11.31, 11.32, 11.34, 11.35, 11.36, 11.38,
      11.39, 11.41, 11.41, 11.41, 11.41, 11.42, 11.43, 11.44, 11.46, 11.48, 11.49,
      11.52, 11.56, 11.59, 11.62, 11.63, 11.70, 11.81, 11.82, 11.86, 11.89, 11.90,
      11.92, 11.98, 12.06, 12.35)
length(men)
length(kob)
meanMen=mean(men)
meanKob=mean(kob)
menvar=var(men)
kobvar=var(kob)
menSd=sd(men)
kobSd=sd(kob)
```

Następnym krokiem było sprawdzenie czy dane posiadają rozkład normalny, w tym celu wykorzystano test Shapiro-Wilka.

```
shapiro.test(men) #badanie czy men posiada rozkład normalny
shapiro.test(kob) #badanie czy kob posiada rozkład normalny
```

Wyniki dla przeprowadzonych testów:

```
> shapiro.test(men) #badanie czy men posiada rozkład normalny

      shapiro-wilk normality test

data:  men
W = 0.93164, p-value = 0.004242

> shapiro.test(kob) #badanie czy kob posiada rozkład normalny

      shapiro-wilk normality test

data:  kob
W = 0.94886, p-value = 0.01746
```

Z otrzymanych wyników widać, że zarówno próbki mężczyzn jak i kobiet nie posiadają rozkładu normalnego, dlatego w celu sprawdzenia hipotezy o równości wariancji nie możemy posłużyć się testem var. Do potwierdzenia bądź odrzucenia hipotezy posłużymy się testem Lavene'a. Można wykorzystać też np.: test Bartletta. Przed przystąpieniem do testu utworzymy jeszcze tabelę wynikową dla danych zawierających m.in. p-value.

```
dane=rbind(c(length(kob),meankob,kobvar,kobsd,shapiro.test(kob)$p.value)
           ,c(length(men),meanMen,menvar,menSd,shapiro.test(men)$p.value))
dane
rownames(dane)=c('kobiety','Mężczyźni')
dane
colnames(dane)=c('n','mean','var','sd','p.value')
dane
```

	n	mean	var	sd	p.value
kobiety	57	11.36667	0.11052976	0.3324602	0.017463297
Mężczyźni	54	10.30074	0.05687114	0.2384767	0.004242284

```
> |
```

W celu przeprowadzenia testu Levene’a należy pogrupować dane oraz długość odpowiednich wektorów zastąpić dowolną zmienną. W naszym przypadku 1 oznaczono mężczyzn, a 2 kobiety.

```
group=c(rep(1,length(men)),rep(2,length(kob)))
levene.test(c(men,kob),group)
```

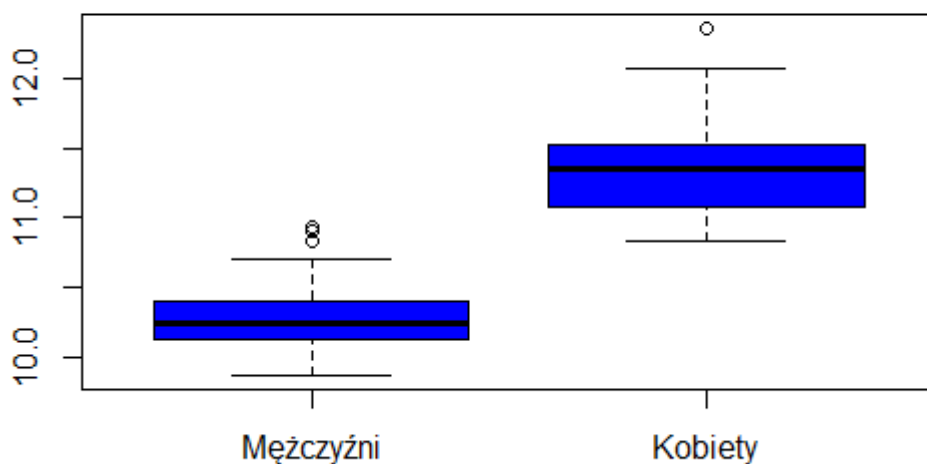
Wyniki testu Levene’a:

```
data: c(men, kob)
Test Statistic = 5.4319, p-value = 0.02161
```

Modified robust Brown-Forsythe Levene-type test based on the absolute deviations from the median

Z otrzymanych wyników że wartość $p\text{-value} < 0.05$ więc należy odrzucić hipotezę o równości wariancji w tych populacjach.

```
boxplot(men,kob,col='blue',names = c('Mężczyźni','kobiety'))
```



Zadanie 2

Pierwszym krokiem jest zbadanie czy rozkłady w prywatnych i publicznych koledżach posiadają rozkład normalny. W tym celu wykorzystano test Shapiro-Wilka

```
publ=c(4.2, 6.1, 4.9, 8.5, 4.6, 9.1, 7.7, 6.5, 6.2, 10.2, 11.6, 10.4,  
        5.0, 10.4, 8.1)  
priv=c(13.0, 18.8, 13.2, 14.4, 17.7, 17.7, 17.6, 19.8, 16.8, 16.1)  
  
shapiro.test(publ)  
shapiro.test(priv)  
  
var.test(publ,priv)  
  
publSd=sd(publ)  
privSd=sd(priv)  
meanPubl=mean(publ)  
meanPriv=mean(priv)
```

Wyniki testu Shapiro-Wilka dla publicznych danych $p\text{-value} > 0.05$ czyli posiada rozkład normalny

```
> shapiro.test(publ)  
  
      shapiro-wilk normality test  
  
data:  publ  
W = 0.93737, p-value = 0.3505
```

Wyniki testu Shapiro-Wilka dla prywatnych danych $p\text{-value} > 0.05$ czyli posiada rozkład normalny.

```
> shapiro.test(priv)  
  
      shapiro-wilk normality test  
  
data:  priv  
W = 0.92813, p-value = 0.4297
```

Z dwóch powyższych zrzutów ekranu widać, czemu zdecydowano się na wykonanie testu `var.test` do analizy wariancji. Wyniki `var.test` przedstawiono poniżej:

```
> var.test(publ,priv)  
  
      F test to compare two variances  
  
data:  publ and priv  
F = 1.0936, num df = 14, denom df = 9, p-value = 0.9203  
alternative hypothesis: true ratio of variances is not equal to 1  
95 percent confidence interval:  
 0.2879463 3.5097118  
sample estimates:  
ratio of variances  
      1.093607
```

Wartość $p\text{-value} > 0.05$ więc możemy potwierdzić hipotezę o równości wariancji. Teraz przechodzimy do badania równości średnich. W tym celu zastosowano `tsum.test`, do którego potrzebujemy danych dotyczących odchylenia standardowego oraz średnich dla próbek prywatnych i publicznych.

Parametry ustawiono $\mu=10$, ponieważ interesuje nas różnica równa lub większa 10 tys. W tym celu parametr `alternative` ustawiono na `'greater'`.

```
publSd=sd(publ)
privSd=sd(priv)
meanPubl=mean(publ)
meanPriv=mean(priv)

tsum.test(meanPubl,publSd,length(publ)
           ,meanPriv,privSd,length(priv),mu = 10,alternative = 'greater')
```

Wyniki testu:

```
> tsum.test(meanPubl,publSd,length(publ)
+           ,meanPriv,privSd,length(priv),mu = 10,alternative = 'greater')

      welch Two Sample t-test

data:  User input summarized values for x and y
t = -19.712, df = 20.054, p-value = 1
alternative hypothesis: true difference in means is greater than 10
95 percent confidence interval:
 -10.60055      Inf
sample estimates:
mean of x mean of y
 7.566667 16.510000
```

Wartość $p\text{-value}=1$ oznacza, że hipoteza postawiona w zadaniu została potwierdzona.

Zadanie 3

Przygotowanie danych oraz zbadanie czy dane posiadają rozkład normalny. Obliczenie różnicy pomiędzy danymi dotyczącymi zapylenia i nie zapylenia rośliny.

```
zaplona=c(0.78,0.76,0.43,0.92,0.86,0.59,0.68)
niezaplona=c(0.21,0.12,0.32,0.29,0.30,0.20,0.14)

var(zaplona)
var(niezaplona)
sd(zaplona)
sd(niezaplona)

shapiro.test(zaplona)
shapiro.test(niezaplona)

roznica=niezaplona-zaplona
```

Wyniki testu Shapiro-Wilka dla próbki `zaplona` przedstawiono poniżej. Jak widać wartość $p\text{-value}>0.05$

```
> shapiro.test(zapylona)

      shapiro-wilk normality test

data:  zapylona
W = 0.96211, p-value = 0.8366
```

Wyniki testu Shapiro-Wilka dla próbki nie zapylona przedstawiono poniżej. Jak widać wartość $p\text{-value} > 0.05$

```
> shapiro.test(niezapylona)

      shapiro-wilk normality test

data:  niezapylona
W = 0.90921, p-value = 0.3904
```

Z otrzymanych wyników widać, że obie próbki przeszły próbę rozkładu normalnego więc do sprawdzenia badanej hipotezy posłużono się t.testem.

```
t.test(niezapylona, zapylona, alternative = 'greater', paired=TRUE, mu=0)
```

Wyniki przedstawiono poniżej:


```
> t.test(niezapylona, zapylona, alternative = 'greater', paired=TRUE, mu=0)

      Paired t-test

data:  niezapylona and zapylona
t = -6.9451, df = 6, p-value = 0.9998
alternative hypothesis: true mean difference is greater than 0
95 percent confidence interval:
 -0.6289256      Inf
sample estimates:
mean difference
 -0.4914286
```

Jak widać wartość $p\text{-value} > 0.05$ stąd nie należy odrzucać hipotezy H_0 . Wyniki dla próbek zapylona oraz niezapylona przedstawiono za pomocą wykresu boxplot:

```
boxplot(list(przed, po), col=5, las=1)
```



Test Shapiro-Wilka dla danych roznicy=niezapylona-zapylona:

```
t.test(roznica,mu=0)
shapiro.test(roznica)

> shapiro.test(roznica)

      shapiro-wilk normality test

data:  roznica
W = 0.78853, p-value = 0.03149
```

Wartość p-value>0.05. Po przeprowadzeniu t.test-u dla danych roznicy wyniki przedstawiono na poniższym rzucie ekranowym:

```
> t.test(roznica,mu=0)

      one sample t-test

data:  roznica
t = -6.9451, df = 6, p-value = 0.0004419
alternative hypothesis: true mean is not equal to 0
95 percent confidence interval:
 -0.6645690 -0.3182881
sample estimates:
mean of x
-0.4914286
```

Wyniki dla pairwise.t.test przedstawiono poniżej:

```
pairwise.t.test(niezapylona,zapylona,alternative = 'greater')
```

```
data: niezapylona and zapylona
      0.43 0.59 0.68 0.76 0.78 0.86
0.59 - - - - - -
0.68 - - - - - -
0.76 - - - - - -
0.78 - - - - - -
0.86 - - - - - -
0.92 - - - - - -

P value adjustment method: holm
```

Zadanie 4

Przygotowanie danych oraz utworzenie wektora z danymi

```
cuk1=c(10.1,10.9,11.2,10.7)
cuk2=c(12.1,11.9,12.3)
cuk3=c(12.3,12.2,13.2,13.5,13.1)
cuk4=c(12.4,12.5,12.9,13.1)


waga=c(cuk1, cuk2, cuk3, cuk4)
```

Podpisanie danych odpowiednim rodzajem cukierków oraz utworzenie ramki danych zawierającej wagi i nazwy cukierków. Przedstawienie danych w formie graficznej w postaci qplot.

```
rodzaj=rep(c("Mleczna", "kokosowa", "Czekoladowa", "Toffi")
           ,c(length(cuk1),length(cuk2),length(cuk3),length(cuk4)))

ramka=data.frame(waga,rodzaj)

qplot(rodzaj,waga,data=ramka,geom="boxplot",main="Cukierki")
```



Wykonanie obliczeń średniej oraz wariancji dla każdego rodzaju cukierków:

```
meanMleczna=mean(cuk1)
meanKokos=mean(cuk2)
meanCzekolada=mean(cuk3)
meanToffi=mean(cuk4)

varMleczna=var(cuk1)
varKokos=var(cuk2)
varCzekolada=var(cuk3)
varToffi=var(cuk4)
```

Zbadanie każdego z czterech rodzajów cukierków testem Shapiro-Wilka w celu sprawdzenia czy mamy do czynienia z rozkładem normalnym.

```
shapiroMleczna=shapiro.test(cuk1)
shapiroKokos=shapiro.test(cuk2)
shapiroCzekolada=shapiro.test(cuk3)
shapiroToffi=shapiro.test(cuk4)
```

Wyniki testu Shapiro-Wilka:

```
> shapiroMleczna

      shapiro-wilk normality test

data:  cuk1
W = 0.96205, p-value = 0.7918
```



```
> shapirokokos
```

```
shapiro-wilk normality test
```

```
data:  cuk2  
W = 1, p-value = 1
```

```
> shapiroCzekolada
```

```
shapiro-wilk normality test
```

```
data:  cuk3  
W = 0.87771, p-value = 0.2991
```

```
> shapiroToffi
```

```
shapiro-wilk normality test
```

```
data:  cuk4  
W = 0.91569, p-value = 0.513
```

Dla każdego z przedstawionych powyżej testów Shapiro-Wilka widać, że wartość $p\text{-value} > 0.05$ co oznacza, że nie możemy odrzucić hipotezy zerowej, że próbki posiadają rozkład normalny.

Przedstawienie wyników w tabeli.

```
dane=rbind(c(length(cuk1),meanMleczna,varMleczna,shapiroMleczna$p.value),  
           c(length(cuk2),meanKokos,varKokos,shapiroKokos$p.value),  
           c(length(cuk3),meanCzekolada,varCzekolada,shapiroCzekolada$p.value),  
           c(length(cuk4),meanToffi,varToffi,shapiroToffi$p.value))  
rownames(dane)=c("Mleczna","kokosowa","Czekoladowa","Toffi")  
dane  
colnames(dane)=c("n","mean","var","p.value")
```

```
> dane
```

	n	mean	var	p.value
Mleczna	4	10.725	0.2158333	0.7918111
kokosowa	3	12.100	0.0400000	1.0000000
Czekoladowa	5	12.860	0.3330000	0.2990715
Toffi	4	12.725	0.1091667	0.5130401

b)

W celu weryfikacji hipotezy o równości wariancji wag wszystkich cukierków należy wykonać test Bartletta. W tym celu grupujemy dane w listę. Następnie na tej liście wykonujemy test Bartletta.

```
lista=list(cuk1,cuk2,cuk3,cuk4)  
bartlett.test(lista)
```

Wyniki testu Bartletta:

```
> bartlett.test(lista)

    Bartlett test of homogeneity of variances

data:  lista
Bartlett's K-squared = 2.3535, df = 3, p-value = 0.5024
```

Z otrzymanych wyników odczytać możemy, że nie możemy odrzucić hipotezy H_0 o równości wariancji wszystkich cukierków, ponieważ wartość $p\text{-value} > 0.05$.